

# 华中科技大学

## 本科生毕业设计（论文）开题报告

题    目：基于多目标优化的人工神经网络结构设计

院    系\_\_\_\_自动化学院\_\_\_\_

专业班级\_\_\_\_自动化 1401 班\_\_\_\_

姓    名\_\_\_\_王 壮\_\_\_\_

学    号\_\_\_\_U201414260\_\_\_\_

指导教师\_\_\_\_潘林强\_\_\_\_

2018 年 03 月

## 开题报告填写要求

### 一、开题报告主要内容：

1. 课题来源、目的、意义。
2. 国内外研究现况及发展趋势。
3. 预计达到的目标、关键理论和技术、主要研究内容、完成课题的方案及主要措施。
4. 课题研究进度安排。
5. 主要参考文献。

二、报告内容用小四号宋体字编辑，采用 A4 号纸双面打印，封面与封底采用浅蓝色封面纸（卡纸）打印。要求内容明确，语句通顺。

三、指导教师评语、教研室（系、所）或开题报告答辩小组审核意见用蓝、黑钢笔手写或小四号宋体字编辑，签名必须手写。

四、理、工、医类要求字数在 3000 字左右，文、管类要求字数在 2000 字左右。

五、开题报告应在第八学期第二周之前完成。

## 开题报告

### 一、 课题来源、目的、意义

人工神经网络(Artificial Neural Network, ANN)，是基于生物学中神经网络的基本原理，在理解和抽象了人脑结构和外界刺激响应机制之后，以网络拓扑知识为理论基础，模拟人脑的神经系统对复杂信息的处理机制的一种数学模型。该模型以并行分布的处理能力、高容错性、智能化和自学习等能力为特征，将信息的加工和存储结合在一起，以其独特的知识表示方法和智能化的自适应学习能力，引起各科学领域的关注。它实际上是一个由大量简单元件相互连接而成的复杂网络，具有高度线性化，能够进行复杂的逻辑操作和非线性关系实现的系统。人工神经网络是深度神经网络的基础，网络的拟合能力随着网络的层次增加而增加。然而过于复杂的网络结构也造成了过拟合以及模型理解困难的问题。

神经网络学习的目的是通过调整网络中的结构参数包括连接权和偏置值使得误差能量  $E$  最小。然而使用传统的单目标优化方法去最小化  $E$  时，不可避免的会遇到局部极小的问题。并且使用传统的单目标优化方法训练出的神经网络结构通常会过分强调对当前训练样本的正确分类能力，而忽视了网络的泛化能力和抗干扰、噪声的能力。还有，从脑科学角度来看，记忆和遗忘是成对出现的，学习中的遗忘更加接近人类的大脑神经系统。可以看出神经网络结构的优化是一个多目标优化问题。

多目标优化问题通常是指在给定区域使多个目标同时达到尽可能最佳的优化问题。一般情况下，多目标优化问题的各个子问题相互矛盾的，一个子目标的改善可能导致其他目标性能降低。这就导致同时是多个目标同时达到最优是不可能的，而只能在它们之间进行协调和折中处理，使各个子目标尽可能的达到最优化。多目标优化问题在工程应用等现实问题中非常普遍并且处于非常重要的地位。自 20 世纪 60 年代早期以来，多目标优化问题引来了越来越多不同背景研究人员的注意力。因此解决多目标优化问题具有非常重要的科研价值和实际意义。

通过多目标优化求解到的解对单一目标函数并不一定是最佳的，但是从整体

来看却是一个最佳的解。并且由于多个目标函数之间通常是相互制约和相互影响的，所以通过多目标优化得到的神经网络结构可以解决一般神经网络中出现的训练时间长、局部极小、泛化能力差、可理解性差的问题。

本课题的目的在于借助多目标优化方法同时优化人工神经网络的权值和网络结构，通过剔除部分影响弱的节点，保留强作用节点，防止模型过拟合，同时增强模型的可理解性。

## 二、 国内外研究现状及发展趋势

可以将多目标优化算法归为两类，分别为传统优化算法和智能优化算法。传统优化算法包括加权法、线性规划法，其实质上就是将多目标函数转换为单目标函数，进而通过单目标优化算法进行求解。智能优化算法主要包括进化算法、粒子群算法等。

**传统优化算法**将多个目标函数线性组合为一个目标函数，例如加权法通过下式：

$$\max f(x) = w_1 f_1(x) + w_2 f_2(x) + \dots + w_i f_i(x) + L$$

从而将多目标问题转换为单目标问题。该算法有几个明显的缺点：一方面，权重参数的很小改变能够引起所求目标向量的较显著的变化；另一方面，不同权重参数的显著改变有可能得到相似的解向量，使解的多样性差。另外，权重集合的均匀分布一般不会产生一个均匀分布的 Pareto 解集。

**多目标进化算法 (MOEA)** 是一类模拟生物进化机制而形成的全局性概率优化搜索方法，在 20 世纪 90 年代中期开始迅速发展，其发展可以分为两个阶段。第一阶段主要有两种方法，不基于 Pareto 优化的方法和基于 Pareto 优化的方法；第二个阶段就是在此基础上提出了外部集这个概念，外部集存放的是当前代的所有非支配个体，从而使解集保持较好的分布度。这个时期提出的多目标进化算法更多地强调算法的效率和有效性。在这两个阶段中，比较典型的多目标进化算法有 NSGA2、PESA2 和 SPEA2。对于这三种算法而言，其优点较多但是其缺点也比较明显的。如 NSGA2 的优点在于运行效率高、解集有良好的分布性，特别对于低维优化问题具有较好的表现；其缺点在于在高维问题中解集过程具有缺陷，解集

的多样性不理想。PESA2 的优点在于其解的收敛性很好，比较容易接近最优面，特别是在高维问题情况下；但其不足之处在于选择操作一次只能选取一个个体，时间消耗很大，而且阶级的多样性不佳。SPEA2 的优点在于可以取得一个分布度很好的解集，特别是在高维问题的求解上，但是其聚类过程保持多样性耗时较长，运行效率不高。

多目标进化算法(MOEA)一般框架所描述的算法思想如下：多目标进化算法通过对种群  $X(t)$  执行选择、交叉和变异等操作产生下一代种群  $X(t+1)$ 。在每一代进化过程中，首先将种群  $X(t)$  中的所有非劣解个体都复制到外部集  $A(t)$  中，然后运用小生境截断算子剔除  $A(t)$  中的劣解和一些距离较近的非劣解个体，以得到个体分布更为均匀的下一代外部集  $A(t+1)$ ，并且按照概率  $p_e$  从  $A(t+1)$  中选择一定数量的优秀个体进入下代种群。在进化结束时，将外部集中的非劣解个体作为最优解输出。

进化算法中最有名的就是 NSGA-II 了，属于多目标遗传算法。但是其对解的选择过程可以用在其他的优化算法上。NSGA-II 算法主要包括三个部分：

### 1. 快速非支配排序

快速非支配排序是一个循环分级过程：首先找出群体中的非支配解集，记为第一非支配层， $i_{\text{rank}} = 1$  ( $i_{\text{rank}}$  是个体  $i$  的非支配值)，将其从群体中除去，继续寻找群体中的非支配解集，然后  $i_{\text{rank}} = 2$ ，直到所有最优解的等级被确定。

### 2. 保留多样性

为了使计算结果在目标空间比较均匀的分布，维持种群多样性，对每个个体计算拥挤距离，选择拥挤距离大的个体，拥挤距离的定义为：

$$L[i]_d = L[i]_d + (L[i + 1]_m - L[i - 1]_m) / (f_m^{\max} - f_m^{\min})$$

其中  $L[i + 1]_m$  是第  $i + 1$  个个体的第  $m$  目标函数值， $f_m^{\max}$  和  $f_m^{\min}$  是集合中第  $m$  个目标函数的最大和最小值。

### 3. 精英策略选择

精英策略就是保留父代中的优良个体直接进入子代，防止获得的 Pareto 最优解丢失。将第  $t$  次产生的子代种群和父代种群合并，然后对合并后的新种群进行非支配排序，然后按照非支配顺序添加到规模为  $N$  的种群中作为新的父代。

**粒子群优化算法(PSO)**是一种源于对鸟群捕食行为的研究而发明的进化计算技术,最先由 Barnhart 博士和 Kennedy 博士于 1995 年提出。它是一种基于迭代的优化工具,系统初始化一组随机解,通过迭代搜寻最优值,不但具有全局寻优能力,而且具有较强的局部寻优能力。在基本粒子群算法中,粒子群由  $n$  个粒子组成,每个粒子的位置  $x_i$  代表优化问题在  $D$  维搜索空间中潜在的解。粒子在搜索空间中以一定的速度飞行,这个速度根据它本身的飞行经验和同伴的飞行经验来动态调整下一步飞行方向和距离。所有的粒子都有一个被目标函数决定的适应值,并且知道自己到目前为止发现的最好位置(个体极值  $p_i$ )和当前的位置( $x_i$ )。除此之外,每个粒子还知道到目前为止整个群体中所有粒子发现的最好位置(全局极值  $p_g$ ),是所有最好位置中的最优值

粒子群算法的数学描述如下:每个粒子  $i$  包含为一个  $D$  维的位置向量  $x_i=(x_{i1}, x_{i2}, \dots, x_{iD})$  和速度向量  $v_i=(v_{i1}, v_{i2}, \dots, v_{iD})$ ,粒子  $i$  搜索解空间时,保存其搜索到的最优经历位置  $p_i=(p_{i1}, p_{i2}, \dots, p_{iD})$ 。在每次迭代开始时,粒子根据自身惯性和经验及群体最优经历位置  $p_g=(p_{g1}, p_{g2}, \dots, p_{gD})$  来调整自己的速度向量以调整自身位置。 $c_1$ 、 $c_2$  是正常数,称之为加速因子; $r_1$ 、 $r_2$  为  $[0, 1]$  中均匀分布的随机数, $d$  为  $D$  维中的维数; $\omega$  是惯性权重因子。由于粒子群算法具有高效的搜索能力,有利于得到多目标意义下的最优解;通过代表整个解集种群,按并行方式同时搜索多个非劣解,也即搜索到多个 Pareto 最优解;同时,粒子群算法的通用性比较好,适合处理多种类型的目标函数和约束,并且容易与传统的优化方法结合,从而改进自身的局限性,更高效地解决问题。因此,将粒子群算法应用于解决多目标优化问题上具有很大的优势。

粒子群算法思想描述如下:初始化种群后,种群的大小记为  $N$ 。基于适应度支配的思想,将种群划分成两个子群,一个称为非支配子集  $A$ ,另一个称为支配子集  $B$ ,两个子集的基数分别为  $n_1$ 、 $n_2$ ,满足两个子群基数之和为  $N$ [13]。外部精英集用来存放每代产生的非劣解子集  $A$ ,每次迭代过程只对  $B$  中的粒子进行速度和位置的更新,并对更新后的  $B$  中的粒子基于适应度支配思想与  $A$  中的粒子进行比较,若  $x_i \in B$ ,  $\omega x_j \in A$ ,使得  $x_i$  支配  $x_j$ ,则删除  $x_j$ ,使  $x_i$  加入  $A$  更新外部精英集;且精英集的规模要利用一些技术维持在一个上限范围内,如密度评估技术、

分散度技术等。最后，算法终止的准则可以是最大迭代次数  $T_{max}$ 、计算精度  $\varepsilon$  或最优解的最大凝滞步数  $\Delta t$  等。

各种多目标优化算法具有一些相同的特性，包括精英保留策略、种群多样性、个体适应度的赋值等。在研究多目标问题时，掌握它们的共性，可以更好的对原有算法进行改进。而掌握各种算法的不同特点则可以了解其长处与不足，为进一步研究提供理论基础。近几年进化计算的迅速发展为多目标优化问题的解决提供新的视野和活力，它不依赖于问题的具体领域，不要求目标函数有明确的解析表达式，对问题的种类有很强的鲁棒性，所以已广泛应用于组合优化、生产调度、机器人、人工生命、生物计算等许多学科。

### 三、 解决方案

#### 1. 预计达到的目标

首先使用 Matlab/Python 编写前馈神经网络；然后使用多目标优化算法作为训练算法替代随机梯度法，同时优化网络结构和权重；最后使用不同结构的网络做分类问题，研究不同结构下网络的性能。

#### 2. 关键理论和技术

机器学习、人工神经网络、Pareto 优化、多目标优化、基于进化的多目标优化。

#### 3. 主要研究内容

1.构造一般性神经网络处理分类问题；2.学习多目标优化算法，编写多目标优化算法；3.基于现有数据，运用多目标优化算法优化神经网络结构，分析优化后结构的特性。

#### 4. 完成课题的方案和主要措施

首先基于现有平台例如 TensorFlow 设计合适的人工神经网络，然后编写多目标进化算法，可以考虑使用第二代非支配排序进化算法(NSGA-II)。使用多目标

进化算法代替梯度下降法对人工神经网络进行优化得到的神经网络结构, 并和使用梯度下降法得到的神经网络结构进行对比, 分析其优缺点。

#### 四、 课题研究进度安排

表 1 课题研究进度安排表

学期	周次	工作任务
第七学期	17 周——20 周	填写课题任务书, 明确下一步任务。
第八学期	1 周——3 周	翻译文献
	4 周	撰写开题报告
	5 周——12 周	设计与研究, 实现预期目标。
	13 周	在实验的基础上, 撰写论文
	14 周	论文查重
	15 周	答辩

#### 五、 主要参考文献

- [1] Jin Y, Sendhoff B. Pareto-based multiobjective machine learning: An overview and case studies. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2008, 38(3): 397-415.
- [2] Deb K, Pratap A, Agarwal S, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II[J]. IEEE transactions on evolutionary computation, 2002, 6(2): 182-197.
- [3] Hüsken M, Jin Y, Sendhoff B. Structure optimization of neural networks for evolutionary design optimization. Soft Computing-A Fusion of Foundations, Methodologies and Applications, 2005, 9(1): 21-28.
- [4] Ishigami H, Fukuda T, Shibata T, et al. Structure optimization of fuzzy neural network by genetic algorithm. Fuzzy Sets and Systems, 1995, 71(3): 257-264.
- [5] Loghmanian S M R, Jamaluddin H, Ahmad R, et al. Structure optimization of neural network for dynamic system modeling using multi-



objective genetic algorithm. Neural Computing and Applications, 2012, 21(6): 1281-1295.

[6] Zhang Q, Li H. MOEA/D: A multiobjective evolutionary algorithm based on decomposition. IEEE Transactions on evolutionary computation, 2007, 11(6): 712-731.

[7] M. Luque, O. Cordon, and E. Herrera-Viedma, "A multi-objective genetic algorithm for learning linguistic persistent queries in text retrieval environments," in Multi-Objective Machine Learning, Y. Jin, Ed. New York: Springer-Verlag, 2006, ch. 25, pp. 585 - 600.

[8] T. Hatanaka, N. Kondo, and K. Uosaki, "Multiobjective structure selection for RBF networks and its application to nonlinear system design," in Multi-Objective Machine Learning, Y. Jin, Ed. New York: Springer-Verlag, 2006, ch. 21, pp. 491 - 505.

[9] H. Ishibuchi and T. Yamamoto, "Evolutionary multi-objective optimization for generating an ensemble of fuzzy rule-based classifiers," in Proc. Genetic Evol. Comput. Conf. Lecture Notes in Computer Science, vol. 2723, 2003, pp. 1077 - 1088

[10] L. Prechelt, "PROBEN1—A set of neural network benchmark problems and benchmarking rules," Fakultät Inf., Univ. Karlsruhe, Karlsruhe, Germany, Tech. Rep., 1994.

## 华中科技大学本科生毕业设计（论文）开题报告评审表

[illegible]